UNIBALSAS

ANÁSILE E DESENVOLVIMENTO DE SISTEMAS

EMILLY KAROLINE CUNHA FERNANDES
THIERRY HANRY RIBEIRO DA SILVA CARDOSO
HÁGAPE LATAN MENDONÇA DE SOUSA
CÉSAR KAYOMA SOUSA DE OLIVEIRA

emilly.cunha@alu.unibalsas.edu.br
thierry.hanry@alu.unibalsas.edu.br
hagape.latan@alu.unibalsas.edu.br
cesar.kayoma@alu.unibalsas.edu.br

DEFINIÇÃO DO PROBLEMA DE DADOS E SELEÇÃO DO CONJUNTO DE DADOS

Orientador: Alex Rogaleski Marques

Disciplina: BIG DATA E CIÊNCIAS DE DADOS

Balsas - MA

2026

1. PROBLEMA DO PROJETO

O projeto foi desenvolvido a partir de uma situação observada na UBS Centenário, localizada no bairro Juá, em Riachão, Maranhão, principalmente no setor da sala de vacinação. A unidade já utiliza um sistema digital para registrar parte das informações relacionadas ao atendimento e à vacinação. Porém, alguns pacientes ainda possuem informações de vacinação antigas somente em suas carteiras de vacinação. Isso acontece principalmente com registros realizados antes da utilização do sistema atual ou que não foram inseridos digitalmente.

Esse tipo de situação pode causar dificuldades para os profissionais da sala de vacina, principalmente quando é necessário consultar o histórico de uma pessoa para verificar quais vacinas já foram aplicadas e quais ainda precisam ser realizadas. Além disso, uma caderneta física pode ser perdida, danificada ou apresentar informações difíceis de ler. Isso aumenta a necessidade de conferir os dados manualmente e pode tornar o atendimento mais demorado. Dessa forma, o problema definido para o projeto é: Como facilitar a digitalização, organização e consulta do histórico de vacinação dos pacientes da UBS Centenário, reduzindo a dependência de registros exclusivamente físicos?

2. SOLUÇÃO PROPOSTA

A ideia é permitir que informações antigas presentes nas cadernetas de vacinação sejam transformadas em registros digitais. Para isso, o sistema poderá utilizar OCR (Reconhecimento Óptico de Caracteres) para auxiliar na leitura das informações presentes nas imagens dos cartões de vacina.

Depois da digitalização, os dados poderão ser organizados de maneira estruturada, facilitando a consulta do histórico. A solução também prevê um chatbot, que poderá auxiliar na consulta das informações e na orientação sobre possíveis próximas doses, utilizando dados como idade, vacinas já registradas, doses recebidas e regras do calendário de vacinação.

3. PRODUTO MÍNIMO VIÁVEL(MVP)

3.1 Registro assistido do histórico vacinal

O usuário poderá inserir ou fotografar uma caderneta ou cartão de vacinação. O sistema utilizará OCR para identificar informações como:

- Nome da vacina;
- Data da aplicação;
- Dose;
- Informações relacionadas ao registro.

Após a leitura, o profissional poderá conferir os dados antes de confirmar o cadastro.

4. NECESSIDADES DE DADOS DA SOLUÇÃO

Essas informações ajuda a organizar o histórico e também servir como base para análises sobre vacinação:

- Identificação da vacina;
- Dose aplicada;
- Data da vacinação;
- Idade do paciente;
- Município;
- Unidade de saúde;
- Grupo de atendimento;
- Estratégia de vacinação;
- Fabricante;
- Lote;
- Via de administração;
- Local de aplicação;
- Informações relacionadas ao registro da vacinação.

5. PESQUISA E COMPARAÇÃO DAS BASES DE DADOS

Antes de escolher a base utilizada no projeto, foram consideradas diferentes bases públicas disponibilizadas pelo Portal de Dados Abertos do SUS, relacionadas às doses aplicadas pelo Programa Nacional de Imunizações. Foram analisadas principalmente as bases anuais do PNI referentes a 2021, 2023, 2024 e 2025. O Portal de Dados Abertos do SUS disponibiliza conjuntos específicos para diferentes anos do PNI, incluindo 2021, 2022, 2023, 2024 e 2025. A comparação foi feita considerando principalmente a relação da base com o problema do projeto, a disponibilidade dos dados, a possibilidade de acesso por arquivos e API e a utilidade das informações para compreender os registros de vacinação.

5.1 COMPARAÇÃO DAS ALTERNATIVAS

Base Pesquisada	Características observadas:	Relação com o projeto:	Decisão:
PNI 2021	Contém registros de doses aplicadas e recursos organizados por período. O portal disponibiliza arquivos em formatos como CSV e também recursos por API.	Possui relação direta com vacinação, mas utiliza dados de um período mais antigo.	Não selecionada.
PNI 2023	Contém dados de vacinação organizados por ano e mês. O portal informa que, devido ao grande volume, os dados são disponibilizados em arquivos mensais e possuem diversas variáveis para análise.	Possui forte relação com o projeto e poderia ser utilizada para análise de registros vacinais.	Não selecionada.
PNI 2024	Base anual de doses aplicadas pelo PNI, disponibilizada pelo Portal de Dados Abertos do SUS.	Possui relação direta com o problema e apresenta dados relativamente recentes.	Não selecionada.
PNI 2025	Base anual mais recente entre as alternativas analisadas, com dados organizados por período e disponibilização por arquivos e API.	Possui relação direta com o projeto e permite trabalhar com dados mais recentes de vacinação.	Selecionada

5.2 JUSTIFICATIVA DA SELEÇÃO

Após a comparação, foi selecionada a base:

Foi escolhido a “Doses aplicadas pelo Programa Nacional de Imunizações (PNI), 2025”, porque o projeto busca trabalhar com informações relacionadas ao histórico e aos registros de vacinação, e essa base apresenta dados diretamente relacionados às doses aplicadas pelo PNI. Além disso, a escolha de um conjunto referente a 2025 permite trabalhar com um período mais recente em relação às alternativas analisadas.

6. CONJUNTO DE DADOS SELECIONADO

A base é disponibilizada pelo Ministério da Saúde, por meio do Departamento do Programa Nacional de Imunizações (DPNI) e do Portal de Dados Abertos do SUS. A escolha dessa base aconteceu porque ela possui relação direta com o tema do projeto, já que contém informações sobre doses de vacinas aplicadas no âmbito do Programa Nacional de Imunizações. O Portal de Dados Abertos do SUS disponibiliza o conjunto PNI 2025 entre as bases públicas relacionadas ao PNI.

7. FONTE E ORIGEM DOS DADOS

Os dados são públicos e disponibilizados pelo Ministério da Saúde, dentro do Portal de Dados Abertos do SUS. A origem institucional dos dados é o Departamento do Programa Nacional de Imunizações (DPNI). A utilização de uma fonte oficial foi importante para o trabalho porque permite consultar uma base pública relacionada diretamente ao tema da vacinação e possibilita a reprodução da pesquisa.

8. LINK PARA ACESSO À BASE

Portal de Dados Abertos do SUS – PNI 2025:
https://dadosabertos.saude.gov.br/dataset/doses-aplicadas-pelo-programa-de-nacional-de-imunizacoes-pni-2025

Também foi utilizada a API de Dados Abertos do Ministério da Saúde para realizar uma primeira consulta aos registros.
Endpoint: https://apidadosabertos.saude.gov.br/vacinacao/doses-aplicadas-pni-2025

REPOSITÓRIO GITHUB:

O desenvolvimento e os arquivos utilizados na realização desta etapa estão disponíveis no repositório GitHub do projeto. Nele podem ser encontrados o documento da TED, os arquivos relacionados ao conjunto de dados utilizado e, quando aplicável, os códigos desenvolvidos para análise dos dados.

Repositório:

https://github.com/thierryhanry2006/Unidade-Basica-de-Saude-UBS-.git

9. Descrição do conjunto de dados

O conjunto selecionado reúne informações relacionadas às doses aplicadas pelo Programa Nacional de Imunizações durante o ano de 2025. Devido ao grande volume de dados, os registros são disponibilizados de forma organizada por período, incluindo recursos mensais. O portal disponibiliza os dados principalmente em arquivos CSV, além de oferecer acesso por API.

10. PRINCIPAIS ATRIBUTOS E VARIÁVEIS

Durante a análise da resposta obtida pela API, foram identificados diversos campos relacionados às doses aplicadas.
Entre os principais estão:

Variável	Descrição
data_vacina	Data em que a vacina foi aplicada
codigo_vacina	Código utilizado para identificar a vacina
codigo_dose_vacina	Código relacionado à dose aplicada
descricao_vacina_fabricante	Descrição da vacina/fabricante
codigo_lote_vacina	Código ou identificação do lote
numero_idade_paciente	Idade do paciente
tipo_sexo_paciente	Sexo informado no registro

nome_municipio_paciente	Município do paciente
sigla_uf_paciente	Estado do paciente
nome_municipio_estabelecimento	Município do estabelecimento
sigla_uf_estabelecimento	Estado do estabelecimento
codigo_cnes_estabelecimento	Código CNES do estabelecimento
descricao_local_aplicacao	Local onde a vacina foi aplicada
descricao_via_administracao	Via utilizada para administração
codigo_estrategia_vacinacao	Estratégia de vacinação
codigo_vacina_grupo_atendimento	Grupo de atendimento relacionado à vacinação
descricao_sistema_origem	Sistema de origem do registro
data_entrada_rnds	Data de entrada do registro na RNDS

Essas variáveis são importantes porque permitem analisar não somente qual vacina foi aplicada, mas também informações relacionadas ao paciente, à aplicação e ao estabelecimento de saúde.

11. QUANTIDADE DE REGISTROS

- Na primeira consulta realizada pela API, foi utilizado o parâmetro: limit = 1000
- Dessa forma, foram obtidos: 1.000 registros na consulta realizada.

É importante destacar que 1.000 não representa o total de registros existentes em todo o PNI 2025, pois os arquivos são extremamente pesados. Esse número corresponde apenas à quantidade retornada nessa consulta da API. O conjunto completo de 2025 é disponibilizado em recursos mensais. Portanto, para obter a quantidade total de registros do ano, será necessário contabilizar os registros dos arquivos correspondentes aos meses de janeiro a dezembro. Neste momento, o número de 1.000 registros deve ser tratado

como a quantidade analisada na primeira consulta, e não como o tamanho total da base.

12. FORMATO DOS DADOS

Os dados do PNI 2025 podem ser acessados por diferentes formatos e também por API. Para este trabalho, foram considerados principalmente:

- CSV, para armazenamento e análise dos arquivos;
- JSON, utilizado na consulta realizada pela API;
- API, utilizada para acessar os registros de forma programática.

O formato CSV é especialmente útil para análise porque pode ser utilizado em ferramentas como Excel, LibreOffice, Python, R e outras ferramentas de análise de dados.

13. JUSTIFICATIVA DA ESCOLHA DA BASE

A base do PNI 2025 foi escolhida porque possui uma relação direta com o problema estudado, o projeto busca organizar informações relacionadas ao histórico de vacinação, para isso, é necessário compreender quais dados são utilizados nos registros das doses aplicadas. A base do PNI apresenta informações como vacina, dose, data, idade, município, estabelecimento, estratégia de vacinação e grupo de atendimento. Esses dados ajudam a compreender a estrutura dos registros de vacinação que poderão ser utilizados como referência para o desenvolvimento da solução. Além disso, a fonte é pública e institucional, o que facilita a consulta e a reprodução da pesquisa.

14. RELAÇÃO ENTRE OS DADOS E O PROBLEMA

O projeto precisa trabalhar com informações como:
Vacina -> Dose -> Data -> Idade/Grupo -> Histórico -> Próxima orientação

A base do PNI contém diversas dessas informações. Os dados podem ajudar no desenvolvimento do sistema porque permitem compreender como os

registros de vacinação são estruturados na prática. Também podem ser utilizada para análises relacionadas às vacinas aplicadas, distribuição de doses, características dos registros e informações dos estabelecimentos. Entretanto, a base pública do PNI não deve ser tratada como o histórico individual dos pacientes da UBS Centenário, ela serve como uma fonte pública de referência e análise e não substitui os dados internos da unidade.

15. POSSÍVEL UTILIZAÇÃO DOS DADOS NA SOLUÇÃO

Os dados selecionados podem contribuir para diferentes etapas do projeto.

- **OCR:** O OCR poderá ser utilizado para transformar informações presentes em cadernetas físicas em dados digitais.
- **Organização do histórico:** Os dados reconhecidos poderão ser organizados em campos estruturados, como vacina, dose e data.

16. AVALIAÇÃO PRELIMINAR DA QUALIDADE DOS DADOS

A utilização de uma base pública oficial apresenta uma vantagem importante: existe uma fonte institucional responsável pela disponibilização dos dados. Alguns cuidados necessários são:

- verificar valores ausentes;
- verificar possíveis duplicidades;
- conferir formatos de datas;
- padronizar nomes e códigos;
- verificar registros inconsistentes;
- conferir códigos de vacinas;
- analisar campos que possam estar incompletos;
- verificar a origem de cada registro.

17. LIMITAÇÕES IDENTIFICADAS INICIALMENTE

Apesar de ser adequada para o estudo, a base apresenta algumas limitações. A principal é que ela não representa diretamente o histórico individual dos pacientes da UBS Centenário. Portanto, a base não pode simplesmente ser utilizada para descobrir o histórico de uma pessoa específica atendida na UBS. Outra limitação é o grande volume de informações. Por esse motivo, os dados são disponibilizados em partes e a API utiliza paginação. Também é necessário considerar que os dados públicos podem possuir campos incompletos ou registros que precisem de tratamento antes de serem utilizados em uma aplicação.

18. TRATAMENTO FUTURO DOS DADOS

Nas próximas etapas da disciplina, os dados poderão passar por procedimentos de preparação, como:

- importar os arquivos;
- verificar a estrutura das colunas;
- identificar valores ausentes;
- verificar registros duplicados;
- padronizar datas;
- conferir códigos;
- separar informações relevantes;
- identificar inconsistências;
- documentar as alterações realizadas;
- preparar os dados para análise.

19. SEGURANÇA E PRIVACIDADE

Como o projeto envolve informações relacionadas à saúde e vacinação, a segurança dos dados deve ser considerada desde o início. A base pública utilizada nesta TED é diferente dos dados pessoais que futuramente poderão ser cadastrados pela UBS.

No desenvolvimento do sistema, os dados dos pacientes deverão receber tratamento adequado, com controle de acesso e cuidados de

segurança. O projeto também deverá considerar os princípios da Lei Geral de Proteção de Dados (LGPD), principalmente porque o sistema poderá trabalhar com informações pessoais relacionadas à saúde.

20. RESULTADO ESPERADO

Com a realização desta etapa, foi possível identificar uma base pública oficial relacionada diretamente ao problema do projeto. Também foram pesquisadas e comparadas diferentes bases anuais do PNI, permitindo escolher aquela que melhor se relaciona com o objetivo desta etapa.

A análise da base selecionada permitiu identificar que os registros de vacinação possuem informações importantes para o desenvolvimento da solução, como vacina, dose, data, idade, estabelecimento, município, estratégia de vacinação e grupo de atendimento. Também foi possível realizar uma primeira consulta à API oficial e obter 1.000 registros para análise. A partir dessas informações, o projeto passa a ter uma referência de dados real para orientar as próximas etapas de desenvolvimento do sistema VACINA.

21. CONCLUSÃO

A teve como objetivo identificar as necessidades de dados do projeto VACINA e selecionar um conjunto de dados público relacionado ao problema definido na disciplina de Inteligência Artificial. Inicialmente, foram analisadas diferentes bases relacionadas às doses aplicadas pelo Programa Nacional de Imunizações, incluindo conjuntos referentes aos anos de 2021, 2023, 2024 e 2025. A comparação considerou principalmente a relação das informações disponíveis com o problema do projeto, a disponibilidade dos dados e a possibilidade de utilização para análise.

Após essa comparação, foi selecionado o conjunto “Doses aplicadas pelo Programa Nacional de Imunizações (PNI) – 2025”, disponibilizado pelo Ministério da Saúde por meio do Portal de Dados Abertos do SUS. A base apresenta informações relacionadas às doses aplicadas, como vacina, dose,

data, idade, estabelecimento, município e grupo de atendimento, que são relevantes para compreender a estrutura dos dados necessários ao projeto.

A consulta realizada pela API permitiu trabalhar inicialmente com 1.000 registros, possibilitando conhecer na prática a estrutura dos dados. Esse número representa apenas os registros retornados na consulta realizada e não o total da base completa.

Dessa forma, a TED 01 estabelece a relação: Problema -> Necessidades de dados -> Bases pesquisadas -> Comparação -> Base selecionada -> Justificativa de utilização.

22. REFERÊNCIAS

BRASIL. Ministério da Saúde. Portal de Dados Abertos do SUS – Doses aplicadas pelo Programa Nacional de Imunizações (PNI) – 2025. Brasília: Ministério da Saúde. Disponível em: https://dadosabertos.saude.gov.br/dataset/doses-aplicadas-pelo-programa-de-nacional-de-imunizacoes-pni-2025

BRASIL. Ministério da Saúde. Portal de Dados Abertos do SUS – Doses aplicadas pelo Programa Nacional de Imunizações (PNI) – 2024. Brasília: Ministério da Saúde. Disponível em: https://dadosabertos.saude.gov.br/dataset/doses-aplicadas-pelo-programa-de-nacional-de-imunizacoes-pni-2024

BRASIL. Ministério da Saúde. Portal de Dados Abertos do SUS – Doses aplicadas pelo Programa Nacional de Imunizações (PNI) – 2023. Brasília: Ministério da Saúde. Disponível em: https://dadosabertos.saude.gov.br/dataset/doses-aplicadas-pelo-programa-de-nacional-de-imunizacoes-pni-2023

BRASIL. Ministério da Saúde. Portal de Dados Abertos do SUS – Doses aplicadas pelo Programa Nacional de Imunizações (PNI) – 2021. Brasília: Ministério da Saúde. Disponível em: https://dadosabertos.saude.gov.br/dataset/doses-aplicadas-pelo-programa-de-nacional-de-imunizacoes-pni-2021

BRASIL. Ministério da Saúde. API de Dados Abertos – Vacinação. Brasília: Ministério da Saúde.

BRASIL. Ministério da Saúde. Programa Nacional de Imunizações – PNI. Brasília: Ministério da Saúde.