UNIBALSAS – Centro Universitário
ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

THIERRY HANRY RIBEIRO DA SILVA CARDOSO
EMILLY KAROLINE CUNHA FERNANDES
CÉSAR KAYOMA SOUSA DE OLIVEIRA
HÁGAPE LATAN MENDONÇA DE SOUSA
thierry.hanry@alu.unibalsas.edu.br
emilly.cunha@alu.unibalsas.edu.br
cesar.kayoma@alu.unibalsas.edu.br
hagape.latan@alu.unibalsas.edu.br

LIMPEZA, SANEAMENTO E ANÁLISE EXPLORATÓRIA DOS DADOS

Orientador: Alex Rogaleski Marques
Disciplina: Big Data e Ciência de Dados

Balsas – MA
2026

1. INTRODUÇÃO

O projeto VACINA foi pensado para melhorar a forma como o histórico de vacinação é organizado e consultado na UBS Centenário. A ideia surgiu principalmente por causa de uma situação bastante comum: parte das informações sobre as vacinas de um paciente ainda pode estar somente na caderneta de vacinação em papel. Quando essa caderneta é perdida, danificada ou não é levada para a unidade de saúde, consultar o histórico pode ficar mais complicado.

A proposta do projeto é criar uma solução que permita registrar essas informações de forma mais organizada, ajudando na digitalização de históricos antigos e, futuramente, utilizando recursos como OCR para auxiliar na leitura das cadernetas. Também está prevista a utilização de regras que possam ajudar na consulta do histórico e no acompanhamento das vacinas.

Para desenvolver uma solução desse tipo, não basta apenas pensar na interface do sistema. Também é importante entender como os dados de vacinação são organizados e quais problemas podem aparecer nesses dados. Por esse motivo, nesta etapa foi utilizada a base pública do PNI 2025, disponibilizada pelo Ministério da Saúde.

A base permite observar informações como data da vacinação, idade, sexo, vacina aplicada, tipo de dose e localização. Além disso, ela possui um volume muito grande de registros, o que torna o conjunto interessante para trabalhar conceitos de Big Data e Ciência de Dados.

Nesta TED 02, o foco foi justamente preparar os dados e entender melhor o que existe neles. Foram verificadas questões como valores ausentes, tipos de dados, possíveis erros de preenchimento, duplicidades, outliers e distribuição dos registros. Depois dessa preparação, foi feita uma análise exploratória para identificar alguns dos principais padrões presentes no conjunto.

2. OBJETIVOS DA ETAPA

O principal objetivo desta etapa foi realizar a limpeza, o saneamento e a análise exploratória dos dados do PNI 2025, deixando a base organizada para análises posteriores e relacionando os resultados encontrados com o projeto VACINA da UBS Centenário.

De forma mais específica, o trabalho buscou:

- carregar e verificar os 12 arquivos mensais do PNI 2025;
- entender a estrutura da base e os principais campos utilizados;
- verificar tipos de dados e valores ausentes;
- identificar idades inválidas e possíveis outliers;
- verificar a existência de duplicidades durante o processamento;
- registrar as regras utilizadas na preparação dos dados;
- calcular estatísticas descritivas;
- analisar a distribuição dos registros por mês, vacina, estado, sexo e tipo de dose;
- relacionar os resultados encontrados com as necessidades do projeto VACINA.

3. CARACTERIZAÇÃO DA BASE DE DADOS

A base utilizada é formada por 12 arquivos CSV, correspondentes aos meses de janeiro a dezembro de 2025. Como o volume de dados é muito grande, não seria viável carregar todos os registros de uma única vez na memória do computador.

Por isso, os arquivos foram processados em blocos. Dessa forma, os dados puderam ser analisados aos poucos, sem a necessidade de manter os mais de 178 milhões de registros carregados simultaneamente.

Durante a análise foram utilizados campos relacionados à data da vacinação, idade do paciente, sexo, imunobiológico, tipo de dose, estado, município e estabelecimento de saúde, entre outros. Essas informações

permitiram observar tanto o comportamento dos registros quanto a qualidade dos dados.

Tabela 1 – Síntese da preparação e saneamento dos dados

Indicador	Resultado	Observação
Registros processados	178.451.615	Total dos 12 arquivos mensais
Arquivos mensais	12	Janeiro a dezembro de 2025
Idades válidas	178.450.559	Utilizadas nas estatísticas de idade
Idades inválidas	1.056	Identificadas na validação do campo de idade
Datas inválidas	0	Nenhuma identificada
Registros sem campos essenciais	0	Nenhum caso encontrado
Duplicidades nos blocos	0	Nenhuma identificada na verificação em blocos
Base preparada para o GitHub	59.994	Amostra preparada para versionamento

Os resultados mostram que, apesar do volume muito grande da base, os principais campos utilizados na análise apresentaram uma boa condição de preenchimento. Os problemas encontrados ficaram mais concentrados em algumas variáveis específicas e na validação da idade.

4. METODOLOGIA DE LIMPEZA E SANEAMENTO

A limpeza foi feita de forma organizada para que fosse possível acompanhar o que estava sendo analisado e quais decisões foram tomadas durante o processo. Os arquivos originais ficaram separados dos resultados gerados, evitando misturar a fonte original com os arquivos utilizados na análise.

O primeiro passo foi realizar a leitura dos 12 arquivos mensais. Como os arquivos são muito grandes, a leitura foi feita em blocos. Também foi necessário considerar a estrutura dos CSVs, incluindo o separador utilizado e a codificação dos arquivos.

Em seguida, foram verificadas as variáveis e seus tipos. A idade, por exemplo, precisava estar em um formato numérico para que fosse possível calcular média, mediana, quartis e desvio-padrão. As datas também passaram por uma validação para confirmar se os valores poderiam ser utilizados corretamente na análise temporal.

Outra parte importante foi a verificação dos valores ausentes. Em vez de simplesmente preencher tudo que estava vazio, foi analisado primeiro quais campos realmente precisavam estar preenchidos e quais poderiam permanecer sem informação.

Também foram identificadas as idades que apresentaram valores inválidos. Esses registros foram separados da análise estatística da idade para não distorcer os resultados.

A verificação de duplicidades foi realizada durante o processamento em blocos. Não foram encontradas duplicidades nessa verificação.

Por último, a idade também foi analisada em relação a possíveis outliers. Para isso, foi utilizado o método do intervalo interquartil, conhecido como IQR. Os valores identificados como possíveis outliers não foram automaticamente eliminados, pois um valor extremo não significa necessariamente que o registro esteja errado.

Para o versionamento do projeto, foi preparada uma base menor, com 59.994 registros, acompanhada dos relatórios e scripts utilizados na análise.

4.1 SÍNTESE ANTES E DEPOIS DA PREPARAÇÃO

A tabela a seguir mostra os principais resultados da preparação dos dados.

Tabela 2 – Situação dos dados antes e depois da preparação

Aspecto	Antes da preparação	Após a preparação
Registros	178.451.615	178.451.615 processados integralmente
Datas inválidas	0	0; campo temporal mantido para a análise
Idades ausentes	0	0; não foi necessária imputação
Idades inválidas	1.056	Separadas das estatísticas; 178.450.559 idades válidas
Campos essenciais ausentes	0	0; nenhum registro foi descartado por esse motivo
Duplicidades nos blocos	0	0 detectadas na verificação em blocos
Outliers superiores de idade	660	Identificados pelo IQR e mantidos para avaliação
Base para versionamento	Base nacional integral	59.994 registros preparados para o GitHub

De forma geral, a preparação teve como objetivo preservar o máximo possível das informações originais. Em vez de excluir registros apenas porque apresentavam alguma característica diferente da maioria, foi priorizada a identificação desses casos e a análise de sua importância.

5. TRATAMENTO DAS IDADES

A idade foi uma das variáveis mais importantes para a análise porque ajuda a entender o perfil dos registros de vacinação e também possui relação com os diferentes grupos e regras do calendário vacinal.

Na validação dessa variável, foram encontrados 178.450.559 valores válidos e 1.056 valores inválidos. Não foram identificados valores ausentes no campo de idade.

Tabela 3 – Estatísticas descritivas da idade

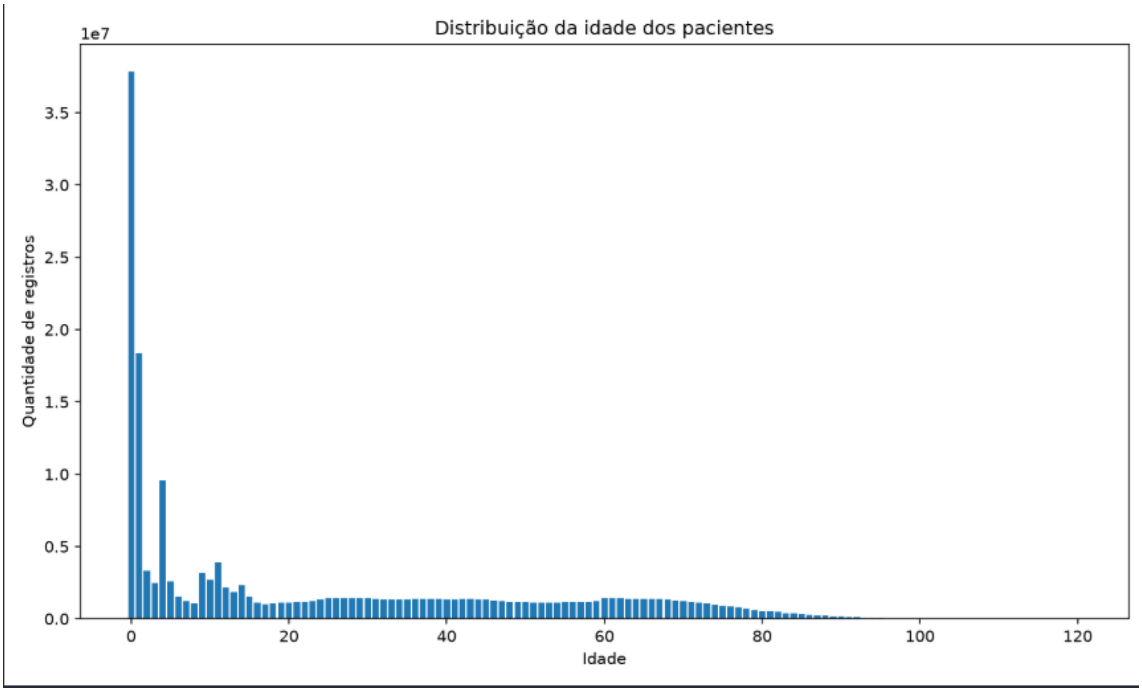
Medida	Resultado
Quantidade válida	178.450.559
Média	24,22 anos
Mediana	12 anos
Mínimo	0 anos
Máximo	120 anos
Desvio-padrão	26,24 anos
1º quartil (Q1)	1 ano
3º quartil (Q3)	45 anos
IQR	44 anos
Limite superior do IQR	111 anos
Outliers superiores	660 registros

Um ponto que chamou atenção foi a diferença entre a média e a mediana. A média ficou em 24,22 anos, enquanto a mediana foi de apenas 12 anos. Isso mostra que os registros não estão distribuídos de forma totalmente equilibrada e que existe uma quantidade considerável de registros em idades adultas, o que acaba aumentando a média.

O primeiro quartil foi de 1 ano e o terceiro quartil foi de 45 anos. A partir desses valores, o IQR foi de 44 anos. Usando esse intervalo, o limite superior calculado foi de 111 anos.

Foram identificados 660 registros acima desse limite. Esses registros foram tratados como possíveis outliers, mas não foram excluídos automaticamente.

Figura 1 - Resumo estatístico da variável idade. Fonte: elaboração própria com base no PNI 2025.



6. ANÁLISE DE VALORES AUSENTES

A análise dos valores ausentes mostrou que nem todas as colunas apresentam o mesmo nível de preenchimento. Algumas variáveis possuem bastante informação faltante, enquanto outras, principalmente as utilizadas como base da análise, apresentam preenchimento completo.

Entre as variáveis principais estão a data da vacinação, a idade, o sexo, a vacina e a dose. Esses campos apresentaram as condições necessárias para a análise realizada.

Tabela 4 – Principais colunas com valores ausentes

Coluna	Ausência	Tratamento
dt_deletado_rnds	100,00%	Sem preenchimento; não utilizado como variável principal
ds_condicao_maternal	45,13%	Mantido como ausente
ds_categoria	42,36%	Mantido sem imputação
ds_via_administracao	4,23%	Ausência preservada

ds_tipo_estabelecimento	4,20%	Ausência preservada
ds_local_aplicacao	4,20%	Ausência preservada
ds_vacina_fabricante	3,88%	Ausência preservada
sg_uf_paciente	1,42%	Ausência preservada
no_uf_paciente	1,41%	Ausência preservada
no_municipio_paciente	1,41%	Ausência preservada
co_municipio_paciente	1,41%	Ausência preservada
no_estrategia	0,91%	Ausência preservada

A principal decisão tomada nessa etapa foi não inventar informações para preencher os campos vazios. Quando não havia uma maneira segura de descobrir qual deveria ser o valor original, o campo permaneceu ausente.

Essa decisão é importante porque uma informação preenchida artificialmente poderia dar a impressão de que o dado veio da fonte original, quando na verdade seria apenas uma estimativa.

7. DUPLICIDADES, DATAS E CONSISTÊNCIA

As datas de vacinação foram verificadas durante o processamento e não foram encontradas datas inválidas. Isso permitiu utilizar a variável temporal normalmente na análise dos meses de 2025.

Também não foram encontrados registros sem os campos definidos como essenciais para a preparação.

Na verificação de duplicidades, não foram identificadas duplicidades dentro dos blocos analisados. Como o conjunto possui um volume muito grande, realizar uma comparação direta de todos os registros ao mesmo tempo seria muito mais pesada para o computador. Por isso, a estratégia em blocos foi utilizada durante o processamento.

É importante destacar que o resultado representa a verificação realizada por essa estratégia.

Os possíveis outliers de idade também não foram removidos automaticamente. Como já foi explicado anteriormente, esses valores podem representar situações reais e, por isso, foram mantidos para avaliação.

8. ANÁLISE EXPLORATÓRIA

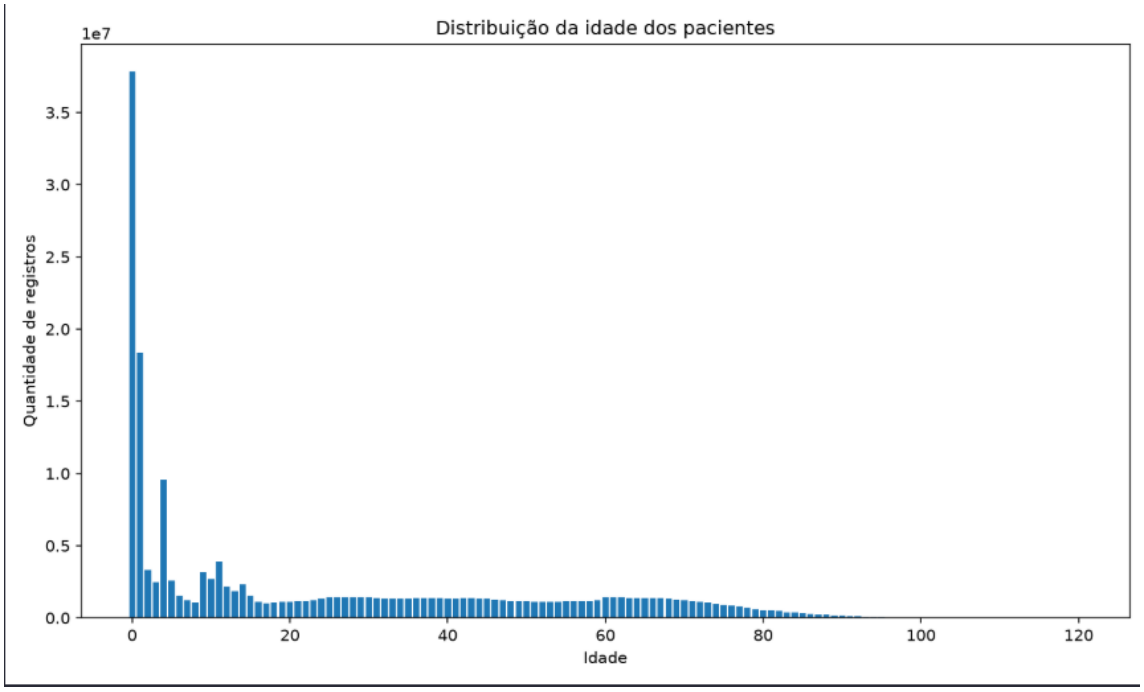
Depois da etapa de limpeza e preparação, foi possível observar alguns padrões interessantes na distribuição dos registros.

8.1 distribuição por idade

Tabela 5 - estatísticas descritivas por idade

Medida	Resultado
Quantidade válida	178.450.559
Média	24,22 anos
Mediana	12 anos
Mínimo	0 anos
Máximo	120 anos
Desvio-padrão	26,24 anos
1º quartil (Q1)	1 ano
3º quartil (Q3)	45 anos
IQR	44 anos
Limite superior do IQR	111 anos
Outliers superiores	660 registros

Figura 1 - Resumo estatístico da idade dos pacientes



O gráfico permite visualizar a diferença entre os principais pontos da distribuição da idade. A mediana ficou em 12 anos, enquanto a média chegou a 24,22 anos. O terceiro quartil foi de 45 anos e o valor máximo observado foi de 120 anos. Também é possível perceber a distância entre o limite superior calculado pelo IQR, de 111 anos, e o valor máximo da base. Essa diferença foi o que levou à identificação dos 660 possíveis outliers superiores.

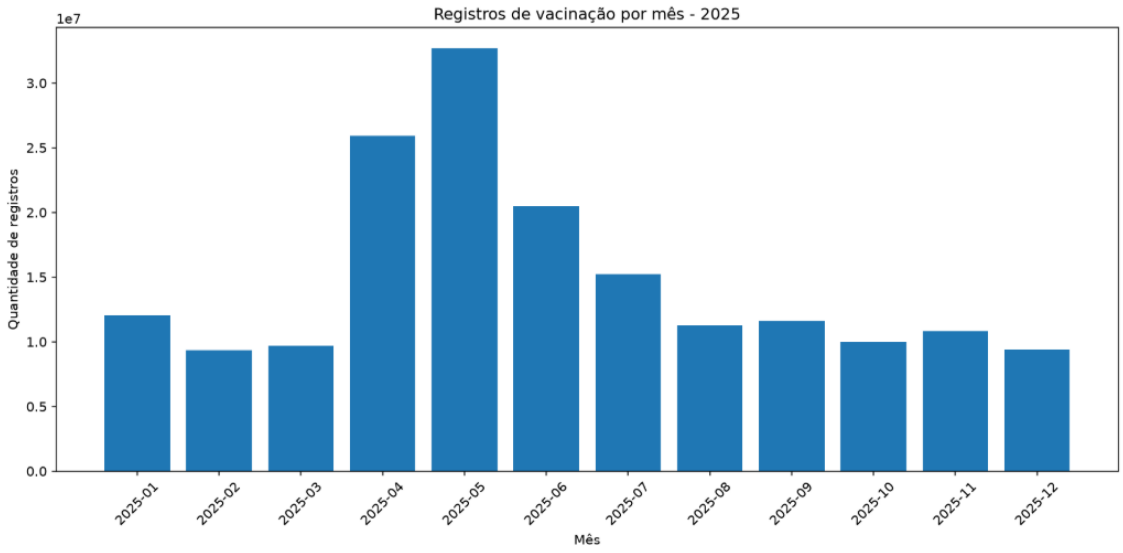
8.2 Distribuição mensal

Tabela 6 - Registros de vacinação por mês

Mês	Registros
Janeiro	12.062.476
Fevereiro	9.334.511
Março	9.712.072
Abril	25.913.391
Maio	32.666.708
Junho	20.466.802

Julho	15.226.105
Agosto	11.244.935
Setembro	11.604.457
Outubro	9.973.489
Novembro	10.839.981
Dezembro	9.406.688

Figura 2 – Distribuição mensal dos registros. Fonte: elaboração própria com base no PNI 2025.



Os registros não ficaram distribuídos de maneira uniforme durante o ano. Nos primeiros meses, os valores ficaram relativamente mais baixos e começaram a aumentar principalmente a partir de abril.

O maior volume apareceu em maio, com 32.666.708 registros. Já fevereiro apresentou o menor valor, com 9.334.511 registros.

Depois do pico de maio, houve uma redução nos meses seguintes, embora o número de registros tenha continuado variando.

Esse comportamento mostra que a procura por vacinação pode mudar bastante durante o ano. Porém, somente com essa base não é possível afirmar exatamente qual foi o motivo dessas diferenças. Para isso, seriam necessárias

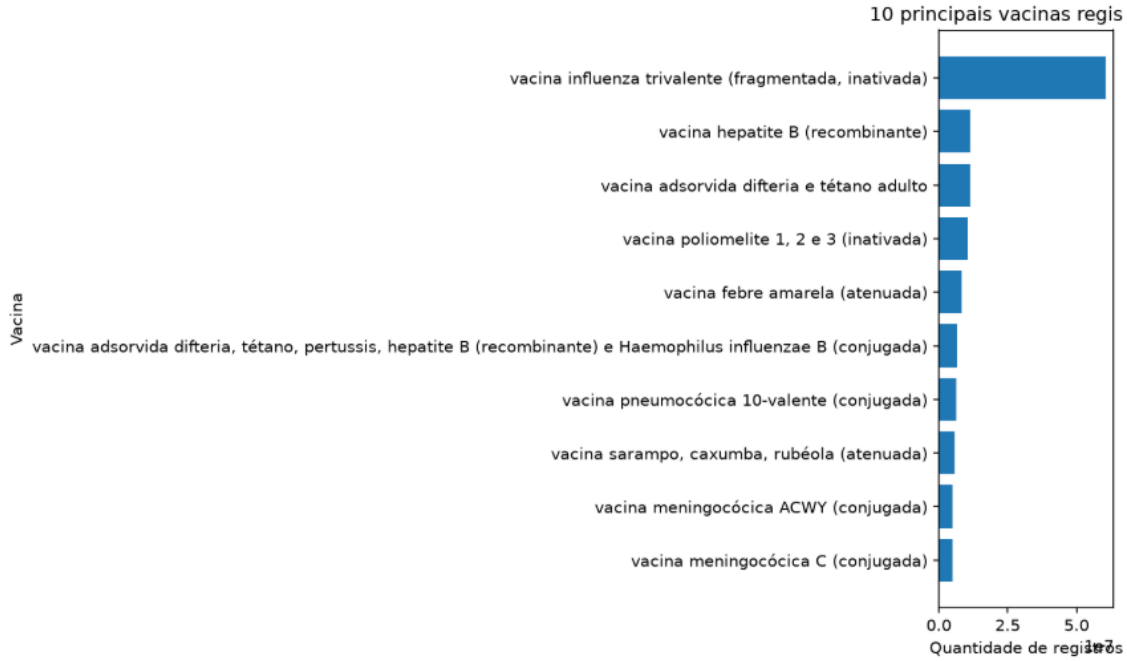
outras informações, como dados de campanhas, calendário de vacinação e características específicas de cada período.

8.3 Vacinas mais frequentes

Tabela 7 - Vacinas com maior número de registros

Posição	Imunobiológico	Registros
1	Influenza trivalente	60.493.978
2	Hepatite B	11.427.555
3	dT	11.422.945
4	VIP	10.601.972
5	Febre amarela	8.295.176
6	Penta	6.532.069
7	Pneumocócica 10V	6.248.130
8	SCR	5.835.854
9	MenACWY	5.016.632
10	MenC	4.853.558

Figura 3 – Vacinas com maior número de registros. Fonte: elaboração própria com base no PNI 2025.



A influenza trivalente foi, de longe, a vacina com maior quantidade de registros, totalizando 60.493.978.

Depois aparecem hepatite B, dT e VIP, com números bem menores em comparação com a influenza.

Esse resultado mostra que algumas vacinas concentram uma parcela muito grande das aplicações registradas durante o ano. Para o projeto VACINA, isso pode ser útil na hora de organizar o cadastro e estruturar as regras relacionadas às vacinas e às doses.

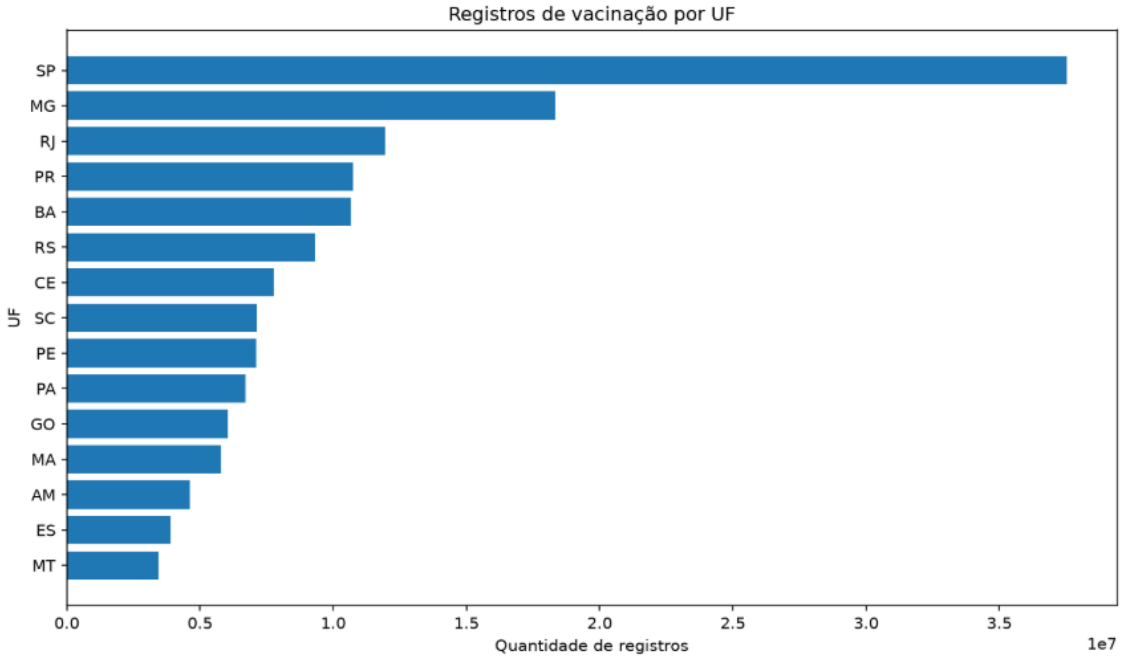
Mesmo assim, é importante lembrar que esses números representam o cenário nacional e não o movimento específico da UBS Centenário.

8.4 Distribuição por unidade federativa

Tabela 8 - Principais unidades federativas por quantidade de registros

UF	Registros
SP	37.532.341
MG	18.339.534
RJ	11.934.495
PR	10.735.663
BA	10.645.711
RS	9.306.957
CE	7.774.212
SC	7.144.636
PE	7.104.152
PA	6.709.744
GO	6.052.722
MA	5.796.555

Figura 4 – Distribuição dos registros nas principais UFs. Fonte: elaboração própria com base no PNI 2025.



São Paulo apresentou a maior quantidade de registros, com 37.532.341, seguido por Minas Gerais, Rio de Janeiro, Paraná e Bahia.

No caso do Maranhão, foram registrados 5.796.555 registros, o que corresponde a aproximadamente 3,25% do total nacional analisado.

Esse resultado é particularmente interessante para o projeto porque o Maranhão é justamente o estado em que está localizada a UBS Centenário. Embora a base seja nacional, observar o comportamento do estado ajuda a aproximar a análise do contexto regional do projeto.

8.5 SEXO E TIPOS DE DOSE

Na variável sexo, foram encontrados:

96.984.897 registros classificados como F;

81.459.490 registros classificados como M;

7.228 registros classificados como I.

A categoria I foi mantida da mesma forma que aparece na base original. Como não foi identificada uma definição segura dessa classificação na documentação utilizada, optou-se por não atribuir um significado por conta própria.

Em relação ao tipo de dose, a categoria mais frequente foi “Única”, com 72.246.157 registros.

Em seguida apareceram:

1ª Dose: 32.813.074 registros;

2ª Dose: 24.951.467 registros;

Reforço: 17.665.180 registros.

Esses dados ajudam a mostrar a variedade de situações que o sistema do projeto poderá precisar representar. Um histórico vacinal não precisa guardar apenas qual vacina foi aplicada, mas também em qual dose e em que momento ela foi registrada.

9. RELAÇÃO DOS RESULTADOS COM O PROJETO DA UBS CENTENÁRIO

Os resultados encontrados nesta etapa têm relação direta com algumas partes do projeto VACINA, mesmo que a base do PNI não represente os pacientes da UBS Centenário.

A principal contribuição da base foi ajudar a entender quais informações normalmente aparecem em registros de vacinação. Entre essas informações estão a vacina aplicada, a dose, a data, a idade e os dados relacionados ao atendimento.

Esses campos podem servir como referência para pensar na estrutura do banco de dados do sistema da UBS. Por exemplo, ao digitalizar o histórico de uma pessoa, será importante guardar qual vacina foi tomada, qual dose foi aplicada e em qual data isso aconteceu.

Outra questão importante observada foi a existência de campos com valores ausentes. Isso mostra que o futuro sistema também precisa saber lidar com informações incompletas.

Uma situação semelhante pode acontecer quando um paciente leva uma caderneta antiga em que algumas informações não estão legíveis ou não foram registradas. Nesse caso, o sistema não deve simplesmente inventar um valor para completar o cadastro.

A análise da idade também pode ser aproveitada no projeto, já que diferentes vacinas e doses estão relacionadas à faixa etária. Da mesma forma, a análise dos tipos de dose ajuda a entender como essas informações precisam ser organizadas.

A parte temporal também é importante. Como a data da vacinação é um dos principais registros do histórico, manter esse campo corretamente estruturado será fundamental para uma futura função de acompanhamento.

Dessa forma, o PNI 2025 funciona como uma referência para entender o domínio dos dados e pensar na estrutura do sistema. O histórico real dos pacientes da UBS, por outro lado, deverá vir dos próprios registros da unidade e das informações fornecidas pelos usuários.

10. LIMITAÇÕES E CUIDADOS NA INTERPRETAÇÃO

Mesmo com os resultados obtidos, é preciso ter alguns cuidados para não tirar conclusões além do que os dados permitem.

Primeiramente, a base analisada é nacional. Portanto, os resultados não representam diretamente a realidade da UBS Centenário.

Também é importante lembrar que a base mostra registros de aplicações e não substitui uma base individual de histórico vacinal dos pacientes.

A verificação de duplicidades foi realizada em blocos durante o processamento. Dessa forma, o resultado deve ser entendido como ausência de duplicidades detectadas dentro da estratégia utilizada.

Os valores de idade considerados outliers também foram mantidos. Isso aconteceu porque um valor extremo não significa necessariamente um erro e poderia representar um registro real.

Outro cuidado está relacionado aos valores ausentes. Quando não havia informação suficiente para recuperar um dado com segurança, o campo foi mantido vazio em vez de receber um valor estimado.

Por fim, as diferenças encontradas entre os meses mostram apenas o comportamento dos registros. Sozinhas, elas não permitem explicar por que determinado mês teve mais ou menos aplicações.

11. CONSIDERAÇÕES FINAIS

A realização desta etapa permitiu conhecer melhor a estrutura e o comportamento da base do PNI 2025. O processamento dos 12 arquivos resultou em 178.451.615 registros analisados, mostrando a dimensão do conjunto de dados utilizado no projeto.

Durante a preparação, foram encontradas 1.056 idades inválidas, enquanto nenhuma data inválida foi identificada e nenhum registro apresentou ausência nos campos considerados essenciais.

Na análise estatística da idade, a média foi de 24,22 anos, enquanto a mediana ficou em 12 anos. Também foram identificados 660 possíveis outliers superiores, considerando o limite de 111 anos calculado pelo método do IQR.

Na distribuição mensal, maio apresentou o maior número de registros, com 32.666.708, enquanto fevereiro teve o menor, com 9.334.511. Entre as vacinas, a influenza trivalente apareceu em primeiro lugar, com 60.493.978 registros.

Outro resultado importante foi a quantidade de registros do Maranhão, que chegou a 5.796.555 no conjunto analisado. Esse dado ajuda a aproximar os resultados nacionais do contexto regional do projeto.

Além dos resultados da análise, foi preparada uma base com 59.994 registros para ser disponibilizada no GitHub, juntamente com os relatórios e os scripts utilizados no processamento.

No geral, esta etapa ajudou a transformar uma grande quantidade de dados em informações mais fáceis de entender e analisar. Também serviu para mostrar quais variáveis podem ser importantes na construção do sistema VACINA. A partir daqui, esses resultados podem servir de base para as próximas etapas do projeto, principalmente na modelagem dos dados, na definição das regras de vacinação e na evolução do MVP.

Repositório do projeto

O código-fonte, os scripts de tratamento dos dados, os resultados da análise exploratória e a base preparada para versionamento estão disponíveis no repositório do projeto no GitHub.

GitHub: https://github.com/thierryhanry2006/Unidade-Basica-de-Saude-UBS-.git

REFERÊNCIAS

BRASIL. Ministério da Saúde. Dados Abertos do SUS: Doses aplicadas pelo Programa Nacional de Imunizações (PNI) – 2025. Brasília, DF: Ministério da Saúde, 2025. Disponível em: https://dadosabertos.saude.gov.br/dataset/doses-aplicadas-pelo-programa-de-nacional-de-imunizacoes-pni-2025

BRASIL. Ministério da Saúde. API de Dados Abertos da Saúde: Doses aplicadas pelo Programa Nacional de Imunizações (PNI) – 2025. Disponível em: https://apidadosabertos.saude.gov.br/vacinacao/doses-aplicadas-pni-2025

PANDAS DEVELOPMENT TEAM. pandas documentation. Disponível em: https://pandas.pydata.org/docs/

PROJETO VACINA. Documentação técnica e scripts de preparação e análise do PNI 2025. Repositório institucional da equipe, 2026.