UNIBALSAS — CENTRO UNIVERSITÁRIO
CURSO DE ANÁLISE E DESENVOLVIMENTO DE SISTEMAS
EMILLY KAROLINE CUNHA FERNANDES
THIERRY HANRY RIBEIRO DA SILVA CARDOSO
CÉSAR KAYOMA SOUSA DE OLIVEIRA
HÁGAPE LATAN MENDONÇA DE SOUSA

VACINA: CHATBOT DE ORIENTAÇÃO VACINAL E LEMBRETES AUTOMÁTICOS PARA A UBS CENTENÁRIO

DOCUMENTO TÉCNICO INTEGRADOR — VERSÃO 3.0

BALSAS — MA
2026

EMILLY KAROLINE CUNHA FERNANDES
THIERRY HANRY RIBEIRO DA SILVA CARDOSO
CÉSAR KAYOMA SOUSA DE OLIVEIRA
HÁGAPE LATAN MENDONÇA DE SOUSA

VACINA: CHATBOT DE ORIENTAÇÃO VACINAL E LEMBRETES AUTOMÁTICOS PARA A UBS CENTENÁRIO

Documento Técnico Integrador — Versão 3.0

Trabalho integrador apresentado às disciplinas de Inteligência Artificial e Big Data e Ciência de Dados, do curso de Análise e Desenvolvimento de Sistemas, como continuidade das etapas anteriores do projeto VACINA.

Instituição: UNIBALSAS — Centro Universitário. Local: Balsas — MA. Ano: 2026.

BALSAS — MA
2026

HISTÓRICO DE ALTERAÇÕES

Data	Versão	Descrição	Responsáveis
31/08/2026	0.1	Definição do tema	Emilly e Thierry
01/09/2026	0.1	Visita técnica e levantamento inicial do problema	Emilly
29/09/2026	1.1	Refinamento do escopo para chatbot de orientação vacinal	Equipe
01/10/2026	2.0	Validação exploratória do problema e definição do MVP	Equipe
03/11/2026	3.0	Integração da modelagem de ML e implementação parcial do chatbot	Equipe

SUMÁRIO

APRESENTAÇÃO 4
1 CONTEXTO DO PROJETO E PROBLEMA 4
2 DADOS: SELEÇÃO, PREPARAÇÃO E ANÁLISE EXPLORATÓRIA 5
3 TED 03 — MODELAGEM PREDITIVA E MACHINE LEARNING 7
4 IMPLEMENTAÇÃO PARCIAL DO MVP — INTELIGÊNCIA ARTIFICIAL 10
5 DIFICULDADES, DECISÕES E PLANO DE CONTINUIDADE 13
6 CONSIDERAÇÕES FINAIS 13
REFERÊNCIAS 14
APÊNDICE A — ARQUIVOS E ACESSO À DEMONSTRAÇÃO 15

APRESENTAÇÃO

Este Documento Técnico Integrador — versão 3.0 — reúne a continuidade do projeto VACINA nas disciplinas de Inteligência Artificial e Big Data e Ciência de Dados. A versão preserva a definição do problema, a validação qualitativa e o MVP descritos na versão 2.0, acrescentando a preparação e a modelagem da base pública do Programa Nacional de Imunizações (PNI) e o estado atual da implementação do protótipo Telegram.

As duas frentes são relacionadas pelo tema da vacinação, mas têm objetivos e dados diferentes. A análise de Big Data investiga padrões em registros nacionais e avalia a classificação do imunobiológico. O chatbot é um protótipo de comunicação com o usuário que calcula datas por regras explícitas. O classificador não está integrado ao bot e não recomenda vacinas ou condutas clínicas.

O documento considera a visita técnica e os relatos descritos na versão 2.0, os scripts e resultados disponíveis no repositório, e a execução local da suíte automatizada. Não foram realizados testes clínicos, pesquisa quantitativa com pacientes, avaliação formal de usabilidade ou implantação pública.

1 CONTEXTO DO PROJETO E PROBLEMA

1.1 Organização e público-alvo

O projeto toma como referência a UBS Centenário, no bairro Juá, em Riachão — Maranhão. O público previsto inclui pacientes atendidos pela unidade — crianças por meio de seus responsáveis, adultos, gestantes e idosos — e a equipe da sala de vacina. A solução é concebida como canal complementar, sem substituir os registros e sistemas utilizados pela unidade.

1.2 Problema identificado e validação inicial

Na visita técnica relatada na versão 2.0, a equipe observou e ouviu que o acompanhamento após a aplicação de doses depende, em parte, das orientações presenciais, das anotações na carteira de vacinação e da memória do usuário. A necessidade identificada foi melhorar a comunicação posterior com o paciente sobre o retorno para doses subsequentes. A validação teve caráter exploratório e qualitativo; não incluiu questionários estruturados, amostra estatística ou testes quantitativos com usuários.

O problema do projeto integrador é como apoiar a organização e a comunicação de informações vacinais, reconhecendo uma frente de análise de dados públicos e outra de prototipação de um canal de orientação. A base nacional estudada não corresponde ao histórico clínico individual dos pacientes da UBS.

1.3 Solução proposta e valor

A proposta combina: (a) preparação e análise de dados públicos de vacinação para compreender padrões e testar uma tarefa de classificação; e (b) um chatbot independente, com fluxo guiado, respostas administrativas e lembretes, cuja data estimada é calculada por regras configuradas. A solução pretende facilitar o acesso à informação, sem substituir a avaliação da equipe de saúde.

1.4 Síntese do Lean Canvas

Elemento	Síntese da versão 2.0
Problema	Falta de canal automatizado de comunicação sobre retorno; esquecimento de datas e dependência de orientação presencial e da carteira.
Público	Pacientes da UBS Centenário e equipe da sala de vacina.
Proposta de valor	Orientação acessível por mensagem e lembretes como complemento ao atendimento.
Solução	Chatbot com fluxo guiado, regras de calendário, FAQ e opção de lembrete.
Canais	Protótipo no Telegram; atendimento presencial permanece como canal oficial da UBS.
Métricas-chave	Concordância com a conferência da equipe, conversas concluídas e tempo de resposta; ainda sem medição com usuários.
Custos e receitas	Desenvolvimento, manutenção, hospedagem e mensageria futura; proposta de serviço público sem cobrança direta.
Vantagem e hipótese	Conhecimento da rotina observado em visita e possibilidade de validar regras públicas com a UBS; impacto no comparecimento ainda não medido.

2 DADOS: SELEÇÃO, PREPARAÇÃO E ANÁLISE EXPLORATÓRIA

2.1 Fonte e recorte

Foi selecionada a base “Doses aplicadas pelo Programa Nacional de Imunizações (PNI) — 2025”, disponibilizada pelo Ministério da Saúde no Portal de Dados Abertos do SUS. A consulta inicial via API, descrita nas etapas anteriores, retornou uma amostra limitada a 1.000 registros; esse número não representava o universo anual. Na TED 02 foram processados os 12 arquivos CSV mensais disponibilizados para 2025, totalizando 178.451.615 linhas lidas.

A preparação processou os arquivos em blocos de 200.000 linhas para reduzir o consumo de memória e produziu uma amostra versionável de até 5.000 registros por mês. O arquivo preparado contém 59.994 registros após limpeza e deduplicação. O identificador usado para amostragem não foi mantido na base exportada ao GitHub.

Fonte: Ministério da Saúde, conjunto PNI 2025. Disponível em: https://dadosabertos.saude.gov.br/dataset/doses-aplicadas-pelo-programa-de-nacional-de-

imunizacoes-pni-2025. API: https://apidadosabertos.saude.gov.br/vacinacao/doses-aplicadas-pni-2025.

2.2 Limpeza e preparação da base

Procedimento/indicador	Resultado documentado
Arquivos e volume	12 CSVs mensais; 178.451.615 registros lidos.
Campos e tipos	Datas convertidas para data; idade numérica; texto aparado e marcadores de ausência normalizados.
Registros inválidos	1.056 idades inválidas; datas inválidas, idades ausentes e campos essenciais ausentes: 0 no relatório.
Duplicidades	0 identificadas nos blocos no relatório; deduplicação final aplicada à amostra preparada.
Idades/outliers	Idades válidas entre 0 e 120; Q1=1, Q3=45, IQR=44; 660 valores acima de 111 foram sinalizados.
Tratamento	Outliers são sinalizados em flag e não removidos automaticamente no processamento TED 02.
Base versionável	59.994 linhas e 21 colunas públicas; amostra de até 5.000 registros por mês.

A base preparada reúne atributos como imunobiológico, tipo de dose, idade, sexo, mês de vacinação e UF. Identificadores diretos de paciente não fazem parte do arquivo preparado para versionamento. Os dados são registros administrativos nacionais e não devem ser interpretados como prontuários longitudinais completos.

2.3 Resultados da análise exploratória

Nos arquivos completos de 2025, a idade registrada apresentou média de aproximadamente 24,2 anos e mediana de 12 anos. O intervalo interquartil foi amplo, com Q1 igual a 1 e Q3 igual a 45. A limpeza identificou 660 observações acima do limite superior calculado pelo IQR; elas foram marcadas para análise, sem exclusão automática da base preparada.

A distribuição variou ao longo dos meses. Maio apresentou o maior volume informado (32.666.708), seguido por abril (25.913.391) e junho (20.466.802). A influenza trivalente (INF3) foi o imunobiológico mais frequente no resumo completo, com 60.493.978 ocorrências; em seguida aparecem hepatite B (HB) e dT. São volumes de registros, não uma contagem validada de pessoas únicas.

A categoria de dose “Única” foi a mais frequente (72.246.157 registros), seguida por “1ª Dose” e “2ª Dose”. São Paulo apresentou o maior volume estadual (37.532.341 registros), enquanto o Maranhão registrou 5.796.555. Esses achados descrevem a base administrativa e não comprovam, isoladamente, cobertura vacinal, atraso ou situação individual.

3 TED 03 — MODELAGEM PREDITIVA E MACHINE LEARNING

3.1 Problema de aprendizagem e relação com o projeto

A tarefa experimental foi definida como classificação multiclasse: estimar a categoria de imunobiológico (sg_imunobiologico) associada a um registro, a partir de atributos de contexto da base preparada. A pergunta exploratória é se idade, sexo, tipo de dose, mês e UF contêm padrões que ajudem a distinguir as categorias registradas.

A tarefa se relaciona ao projeto por analisar padrões nos dados de vacinação e exercitar o processo de modelagem e avaliação. Ela não responde à pergunta clínica "qual vacina esta pessoa deve receber?" e não fornece regra para determinar uma próxima dose. O modelo não utiliza histórico individual longitudinal, não está conectado ao chatbot e não foi proposto para decisão clínica.

3.2 Variável-alvo e atributos

Papel	Variável	Justificativa
Alvo (y)	sg_imunobiologico	Categoria registrada do imunobiológico; 46 classes após o filtro de frequência.
Entrada numérica	nu_idade_paciente	Faixa etária pode estar associada às aplicações registradas.
Entradas categóricas	tp_sexo_paciente; ds_tipo_dose; mes_vacinacao; sg_uf_paciente	Características demográficas, temporais e geográficas disponíveis.
Não utilizadas	IDs, município, códigos de pessoa e campos não definidos	Redução de identificadores e foco nas variáveis do protocolo.

3.3 Preparação para modelagem

O script removeu linhas sem classe-alvo e excluiu 120 registros pertencentes a classes com menos de 20 exemplos, permitindo estratificar a separação e a validação cruzada. O arquivo usado tinha 59.994 registros; a modelagem manteve 59.874 registros e 46 classes. Nenhum outlier de idade foi removido nessa amostra segundo o resumo do experimento. Valores categóricos ausentes ou vazios são tratados como "Não informado"; idade ausente é imputada pela mediana dentro do pipeline.

A idade passa por imputação pela mediana e padronização. Variáveis categóricas passam por codificação one-hot, com categorias desconhecidas ignoradas. O pré-processamento foi inserido em pipelines do scikit-learn para que cada partição ajuste suas transformações sem usar dados do conjunto de teste.

3.4 Algoritmos e justificativa

Foram comparadas árvores de decisão com profundidade 5, 10 e 15; K-vizinhos mais próximos (KNN) com k=3, 5 e 7; e Random Forest com 120 árvores, profundidade

máxima 20, mínimo de duas amostras por folha e pesos balanceados por subamostra. As árvores oferecem uma referência interpretável, o KNN um método baseado em proximidade e a Random Forest combina árvores para capturar relações não lineares. A seleção foi feita pelo F1 macro médio na validação cruzada, não pelo teste.

3.5 Estratégia de treino e avaliação

Os dados foram separados em 80% para treino e 20% para teste, com estratificação por classe, semente 42 e teste reservado de 11.975 linhas. No conjunto de treino, a comparação usou validação cruzada estratificada de três partições. Para manter o custo computacional viável, a validação cruzada utilizou até 15.000 linhas do conjunto de treino; o conjunto de teste permaneceu fora da seleção. Como linha de base, avaliou-se um classificador ingênuo que sempre prevê a classe mais frequente.

Foram calculadas acurácia, precisão macro, recall macro e F1 macro. A acurácia resume acertos globais, mas pode ser dominada pelas classes frequentes. As médias macro atribuem o mesmo peso a cada classe e revelam melhor o desempenho nas classes minoritárias; por isso, o F1 macro orientou a escolha.

3.6 Resultados da validação cruzada

Modelo	Acurácia média	Precisão macro	Recall macro	F1 macro
Random Forest (120 árvores)	0,4828	0,2806	0,3304	0,2875
Árvore de decisão (prof. 15)	0,4127	0,2864	0,3141	0,2663
KNN (k=7)	0,4637	0,2304	0,2168	0,2200

A Random Forest apresentou o maior F1 macro médio entre os candidatos avaliados (0,2875; desvio padrão de 0,0065) e foi escolhida para a avaliação final. A árvore de profundidade 15 obteve precisão macro próxima, mas menor F1 macro. Os números descrevem a amostra e a estratégia de validação usadas.

3.7 Avaliação no teste reservado

Modelo no teste	Acurácia	Precisão macro	Recall macro	F1 macro
Linha de base — classe mais frequente	0,2489	0,0054	0,0217	0,0087
Random Forest selecionada	0,4760	0,3037	0,3824	0,3120

A Random Forest obteve acurácia de 47,6%, acima dos 24,9% da linha de base. O F1 macro subiu de 0,0087 para 0,3120, indicando que o classificador aprendeu padrões além de simplesmente repetir a classe mais comum. Ainda assim, F1 macro de 0,312 é modesto para uso operacional e a precisão macro de 0,304 mostra desempenho desigual

entre as classes. O relatório de classificação registrou F1 ponderado de 0,50, maior que o macro, compatível com desempenho melhor nas categorias numerosas.

Classe ilustrativa	Suporte	Precisão	Recall	F1
INF3	2.981	0,91	0,66	0,77
DTP	330	0,85	0,96	0,90
HB	868	0,49	0,29	0,36
VPC10	505	0,26	0,15	0,19
DTPa/VIP	4	0,00	0,00	0,00

Os exemplos mostram heterogeneidade: DTP teve bom F1, enquanto HB e VPC10 tiveram recall reduzido; uma classe com suporte de quatro ocorrências não foi reconhecida no teste. Mesmo após o filtro mínimo de 20 registros no conjunto completo, algumas classes têm pouco suporte na partição de teste. A matriz de confusão e o relatório completo estão em data/processed/TED3_resultados/.

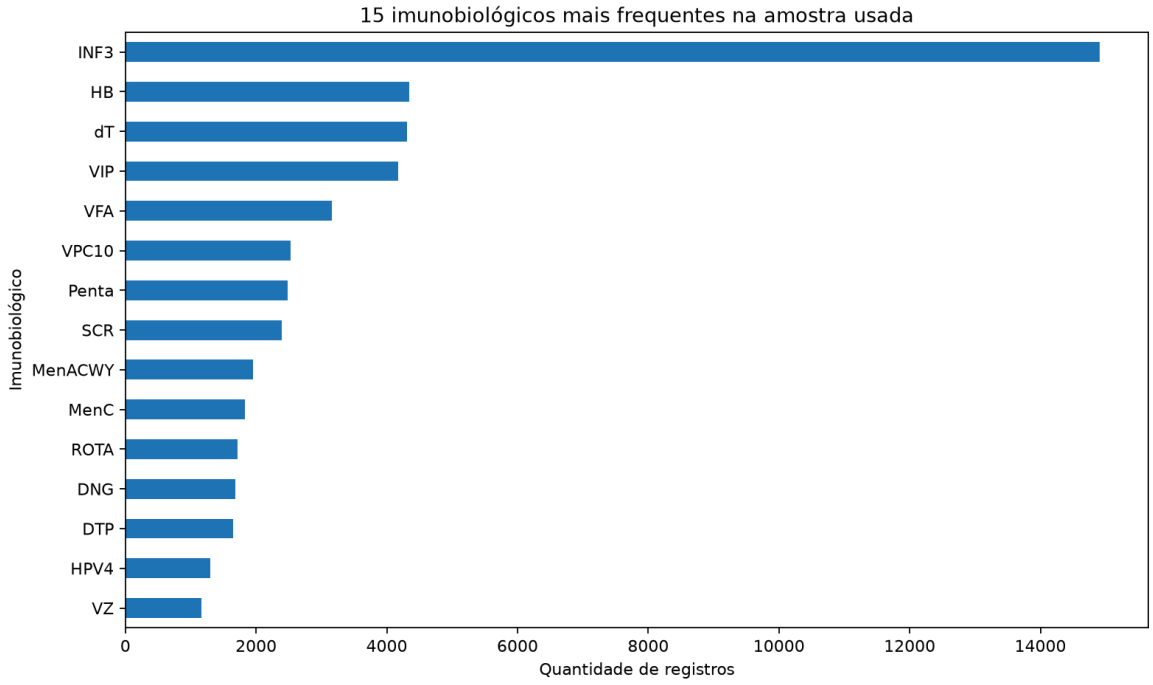


Figura 1 — Quinze imunobiológicos mais frequentes na amostra da modelagem. Fonte: elaboração da equipe.

3.8 Interpretação, limitações e aplicabilidade

O experimento demonstra que os atributos selecionados carregam informação preditiva para reproduzir padrões da base, mas não permite concluir que se possa identificar com segurança a vacina indicada para um paciente. O alvo descreve um registro já

realizado, não uma recomendação futura. O desempenho é limitado, especialmente para classes raras, e pode refletir diferenças de disponibilidade, registro ou práticas regionais.

- Desbalanceamento entre as 46 classes; mesmo com ponderação e métricas macro, várias categorias têm recall ou F1 baixos.
- Amostra de até 5.000 registros por mês; não representa análise direta de todos os 178 milhões de registros nem amostra clínica da UBS.
- Separação aleatória dentro de 2025; não houve teste temporal em outro ano ou avaliação em unidade/município independente.
- As variáveis são observacionais e não demonstram causalidade; mês e UF podem refletir fatores administrativos ou de oferta.
- Métricas dependem do recorte, do filtro mínimo de frequência e da qualidade dos registros do PNI.
- A Random Forest e seus resultados não estão integrados ao chatbot nem validados para qualquer decisão de saúde.

A aplicabilidade atual é acadêmica e exploratória: documentar um fluxo reproduzível de preparação, comparação e avaliação, e apontar padrões e limitações dos dados. Para a evolução do MVP, o modelo não deve substituir regras clínicas. Uma eventual integração exigiria nova definição de problema, validação independente e autorização da equipe de saúde.

4 IMPLEMENTAÇÃO PARCIAL DO MVP — INTELIGÊNCIA ARTIFICIAL

4.1 Arquitetura e tecnologias

O protótipo é executado localmente por Python, com polling do Telegram, sem hospedagem permanente. A arquitetura separa interface e fluxo, classificação de intenção, cálculo determinístico, persistência de lembretes e agendamento. As tecnologias do código são python-telegram-bot; scikit-learn com TF-IDF e similaridade do cosseno; JSON para regras, FAQ e exemplos; python-dateutil; SQLite; APScheduler; e pytest.

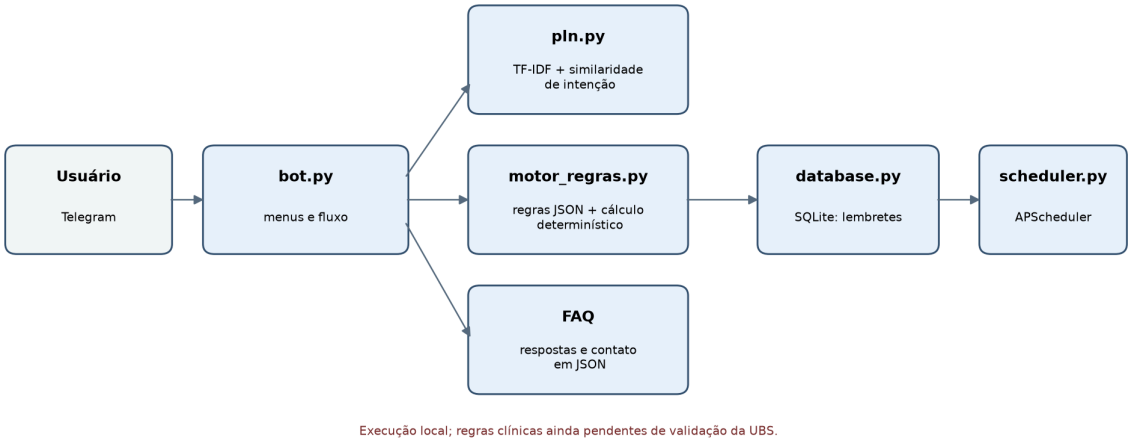


Figura 2 — Arquitetura lógica do protótipo local. Fonte: elaboração da equipe.

4.2 Funcionalidades implementadas

- Menu Telegram com opções de próxima dose, perguntas frequentes e falar com a unidade.
- Fluxo guiado que valida data de nascimento, vacina, número da última dose e data da aplicação.
- Classificação local de intenção textual em próxima dose, FAQ, contato ou intenção desconhecida; o PLN apenas encaminha o fluxo.
- Motor determinístico que consulta regras em JSON, calcula datas quando o cenário está coberto e encaminha casos fora do escopo à UBS.
- Aviso de segurança e bloqueio de cálculo sem validação clínica, exceto no modo de teste, com identificação de simulação.
- FAQ e contato configuráveis por JSON; informações de horário e contato ainda têm itens pendentes de validação local.
- Opção de lembrete, persistência mínima em SQLite e agendamento para o dia anterior à data prevista, às 09h no fuso America/Fortaleza.
- Estados operacionais de lembrete: pendente, enviado, falha ou expirado.

4.3 Fluxo do usuário e evidências

O fluxo implementado pode ser resumido da seguinte forma:

Etapa	Comportamento do protótipo
1. Entrada	Usuário abre /start ou envia mensagem; bot apresenta menu e aviso de privacidade.
2. Intenção	Botões ou classificador textual direcionam para próxima dose, FAQ ou contato.
3. Coleta	Fluxo de dose solicita nascimento, vacina, número e data da última dose.

4. Regra e resposta	Valida o cenário; calcula pela regra JSON somente em modo habilitado e apresenta aviso informativo.
5. Lembrete	Se aceito, salva chat_id, vacina e datas necessárias; o agendador envia o aviso.

Como o protótipo não está hospedado e não havia instância ativa para captura, este documento não apresenta capturas de uma conversa real. As evidências disponíveis são o fluxo, a arquitetura, os testes automatizados e os arquivos de resultados reproduzíveis. Não houve teste de usabilidade com pacientes.

4.4 Testes e resultados preliminares

A suíte automatizada foi executada localmente com pytest na pasta chatbot-vacinas. Resultado observado em 03/11/2026: 31 testes aprovados. Os testes cobrem menu e fluxos do bot, persistência de lembretes, cálculo do motor de regras, classificação de intenções e agendamento. Eles verificam comportamento de software; não validam clinicamente o calendário, as regras junto à UBS ou o impacto sobre comparecimento.

Evidência	Resultado	Interpretação
Suíte pytest	31 passed	Testes automatizados dos módulos passaram localmente.
Validação clínica	Pendente	Regras JSON não liberadas para produção; resultados são simulação.
Teste com usuários	Não realizado	Usabilidade e compreensão das mensagens precisam ser avaliadas.
Disponibilidade	Execução local	Sem aplicação web ou bot público permanente; depende do processo em execução.

4.5 Privacidade, segurança e limites operacionais

Nascimento e dados da última dose permanecem no estado temporário da conversa. A tabela SQLite guarda somente chat_id, identificador da vacina, data prevista, data do lembrete e status; chat_id é pseudônimo e requer acesso restrito. O arquivo local de banco não é evidência de operação em produção. O token Telegram deve ser fornecido por variável de ambiente e nunca publicado.

As regras do PNI estão marcadas como pendentes de validação clínica e sem liberação para produção. Sem o modo de teste, o bot bloqueia cálculo enquanto esse estado persistir. O modo de teste pode enviar mensagens reais à conta conectada, identificadas como simulação; por isso devem ser usados dados fictícios e destinatários controlados. O agendador depende do processo local permanecer ativo e não envia retroativamente lembretes vencidos.

5 DIFICULDADES, DECISÕES E PLANO DE CONTINUIDADE

5.1 Dificuldades encontradas e soluções adotadas

Dificuldade	Decisão/solução adotada
Grande volume dos CSVs	Leitura em blocos de 200 mil linhas e estatísticas agregadas; amostra mensal versionável.
Categorias raras e desbalanceadas	Filtro mínimo 20, validação estratificada, pesos e métricas macro; limitação documentada.
Custo da validação	Validação cruzada limitada a até 15 mil linhas do treino; teste final reservado.
Diferença entre ML e recomendação	Separação explícita: ML analisa registros; chatbot usa regras determinísticas.
Regras clínicas sem validação	Bloqueio para produção, modo de simulação e aviso obrigatório.
Ausência de implantação contínua	Protótipo executado localmente; publicação e monitoramento ficam para etapa posterior.

5.2 Planejamento das atividades restantes

Atividade restante	Condição de conclusão
Revisar regras e intervalos com a UBS	Obrigatória antes de qualquer uso clínico; registrar validação e data.
Confirmar FAQ, endereço, telefone e horários	Validar diretamente com a unidade e remover textos provisórios.
Testes de usabilidade com equipe e voluntários	Consentimento, roteiro controlado e registro de achados.
Reproduzir e documentar experimento de ML	Dependências, versão de dados, execução, métricas e limitações.
Ampliar avaliação do modelo	Testar outros anos ou validação temporal; investigar erros por classe.
Preparar hospedagem e monitoramento	Definir operação, backup, acesso ao SQLite, falhas e disponibilidade.
Atualizar repositório e documento	Conferir links, PDF, código, dados permitidos e acesso para avaliação.

6 CONSIDERAÇÕES FINAIS

A versão 3.0 registra a continuidade do projeto nas duas disciplinas sem confundir suas finalidades. Na frente de Big Data e Ciência de Dados, foi processada uma base pública extensa e treinado um classificador multiclasse; a Random Forest superou a linha de base, mas os resultados por classe e o F1 macro mostram limitações importantes. O modelo é exploratório e não tem aplicação clínica validada.

Na frente de Inteligência Artificial, foi implementado um protótipo local Telegram com menus, PLN leve para intenção, regras determinísticas, FAQ e lembretes, acompanhado de 31 testes automatizados aprovados. Validação clínica, testes com usuários

e disponibilização contínua ainda não foram concluídos. A contribuição principal desta etapa é uma implementação parcial rastreável, com limites explicitados, e uma base de experimentação reproduzível para orientar as próximas decisões do MVP.

REFERÊNCIAS

APScheduler. User guide. Disponível em: https://apscheduler.readthedocs.io/. Acesso em: 3 nov. 2026.

BUTANTAN. Maioria dos municípios brasileiros não atingiu a meta de cobertura para vacinas do calendário infantil em 2023. Instituto Butantan, 23 fev. 2024. Disponível em: https://butantan.gov.br/noticias/maioria-dos-municipios-brasileiros-nao-atingiu-a-meta-de-cobertura-para-vacinas-do-calendario-infantil-em-2023. Acesso em: 1 set. 2026.

CONFEDERAÇÃO NACIONAL DE MUNICÍPIOS. Estudo técnico: avaliação das coberturas vacinais de rotina do PNI no Brasil, de 2010 a 2024. Brasília: CNM, 2025. Disponível em: https://cnm.org.br/biblioteca/download/16281. Acesso em: 2 set. 2026.

LEAL, Iago Brenner Farias et al. Análise da cobertura vacinal infantil atual no Brasil: impacto regional e temporal nos últimos três anos. Cadernos Cajuína, v. 11, n. 1, jan. 2026. Disponível em: https://doi.org/10.52641/cadcajv11i1.1710. Acesso em: 1 set. 2026.

MINISTÉRIO DA SAÚDE (Brasil). Doses aplicadas pelo Programa Nacional de Imunizações (PNI) — 2025. Portal de Dados Abertos do SUS. Disponível em: https://dadosabertos.saude.gov.br/dataset/doses-aplicadas-pelo-programa-de-nacional-de-imunizacoes-pni-2025. Acesso em: 3 nov. 2026.

MINISTÉRIO DA SAÚDE (Brasil). Relatório da OMS e do Unicef mostra aumento da vacinação infantil no Brasil. Brasília: Gov.br, jul. 2026. Disponível em: https://www.gov.br/saude/pt-br/assuntos/noticias-ms/2026/julho/relatorio-da-oms-e-do-unicef-mostra-aumento-da-vacinacao-infantil-no-brasil. Acesso em: 1 set. 2026.

PYTHON-TELEGRAM-BOT. Documentation. Disponível em: https://docs.python-telegram-bot.org/. Acesso em: 3 nov. 2026.

SALGADO, João Felipe Almeida. Queda na cobertura vacinal infantil no Brasil. BVS, [2025?]. Disponível em: https://fi-admin.bvsalud.org/document/view/n6y7r. Acesso em: 1 set. 2026.

SCIKIT-LEARN. User guide: machine learning in Python. Disponível em: https://scikit-learn.org/stable/user_guide.html. Acesso em: 3 nov. 2026.

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL. Brasil enfrenta queda na cobertura vacinal e aumento de doenças preveníveis. Humanista, UFRGS, 18 set. 2025. Disponível em: https://www.ufrgs.br/humanista/2025/09/18/brasil-enfrenta-queda-na-cobertura-vacinal-e-aumento-de-doencas-preveniveis/. Acesso em: 1 set. 2026.

APÊNDICE A — ARQUIVOS E ACESSO À DEMONSTRAÇÃO

Repositório Git: https://github.com/thierryhanry2006/Unidade-Basica-de-Saude-UBS-/tree/dev. Os scripts e relatórios da TED 03 estão organizados em notebook/TED3/ e data/processed/TED3_resultados/. O protótipo Telegram está na pasta chatbot-vacinas/.

Link de aplicação ou ambiente público: não disponível nesta etapa. O chatbot é executado localmente e não está hospedado permanentemente. Para demonstração controlada, seguir as instruções do README da pasta chatbot-vacinas, usar token próprio em variável de ambiente e habilitar modo de teste somente com dados fictícios.

Os resultados incluem comparação de validação cruzada, métricas de teste, distribuição de classes, matriz de confusão, relatório de classificação, resumo de preparação e gráfico das classes mais frequentes. A reprodução requer obter os dados do PNI 2025 e instalar as dependências indicadas no projeto.